

Gold artifact – Evaluation

Case study: Appointment Booking System

1. Cel

Zapewnienie jednolitego sposobu:

- oceny artefaktów z poszczególnych etapów,
- porównywania trybów: human-only / LLM-only / hybrid,
- analizy propagacji błędów,
- agregacji wyników do raportu końcowego.

2. Zakres oceny

Ocena obejmuje:

- requirements,
- architecture,
- code,
- tests,
- DevOps,
- zgodność end-to-end.

3. Tryby porównania

Dla każdego case study i każdego etapu porównywane są:

- Human-only
- LLM-only
- Hybrid

4. Wspólne metryki 0–3

M1. Correctness

- 0 – wynik błędny
- 1 – częściowo poprawny
- 2 – w większości poprawny
- 3 – poprawny

M2. Completeness

- 0 – brakuje większości elementów
- 1 – brakuje istotnych elementów
- 2 – prawie kompletny
- 3 – kompletny

M3. Consistency

- 0 – liczne niespójności
- 1 – zauważalne niespójności
- 2 – zasadniczo spójny
- 3 – spójny

M4. Clarity / Explainability

- 0 – nieczytelny
- 1 – trudny w interpretacji
- 2 – czytelny
- 3 – bardzo czytelny

M5. Practical usefulness

- 0 – nieużywalny
- 1 – wymaga dużych poprawek
- 2 – używalny po poprawkach
- 3 – gotowy lub prawie gotowy

5. Metryki systemowe

E1. Cross-phase consistency

Ocena zgodności:

- requirements ↔ architecture
- architecture ↔ code
- code ↔ tests
- tests ↔ pipeline

E2. Error propagation

Ocena, czy błąd z wcześniejszego etapu:

- został usunięty,
- został przeniesiony dalej,
- został wzmocniony.

E3. Final system quality

Ocena końcowego wyniku pipeline:

- czy system działa,
- czy testy przechodzą,
- czy pipeline działa poprawnie.

6. Referencyjna tabela oceny artefaktu

Artifact ID	Team	Mode	Correctness	Completeness	Consistency	Clarity	Usefulness	Final score
CS1-REQ-LLM	Requirements	LLM-only	2	2	1	3	2	2.0
CS1-ARCH-H	Architecture	Human-only	3	2	3	2	3	2.6
CS1-CODE-HY	Coding	Hybrid	3	3	2	2	3	2.6

7. Referencyjna tabela oceny pipeline

Case Study	Mode	Req→Arch	Arch→Code	Code→Tests	Tests→DevOps	Error Propagation	Final Quality
Booking	Human-only	3	3	3	3	3	3
Booking	LLM-only	2	2	2	2	1	2

Case Study	Mode	Req→Arch	Arch→Code	Code→Tests	Tests→DevOps	Error Propagation	Final Quality
Booking	Hybrid	3	3	2	3	2	3

8. Referencyjna klasyfikacja błędów

Każdy wykryty błąd przypisywany jest do jednej z kategorii:

- R-Ambiguity – błąd interpretacji wymagań
- A-Design – błędna decyzja architektoniczna
- C-Logic – błąd logiki w kodzie
- C-Refactor – regresja po refaktoryzacji
- T-Coverage – brak pokrycia wymagania przez test
- T-FaultDetection – test nie wykrył istotnego błędu
- D-Config – błąd konfiguracji CI/CD
- D-Diagnosis – błędna diagnoza logów/pipeline
- X-Consistency – niespójność między artefaktami

9. Referencyjna tabela analizy błędów

Error ID	Case Study	Stage Introduced	Stage Observed	Category	Severity	Propagated	Comment
E01	Booking	Requirements	Architecture	R-Ambiguity	High	Yes	Niejasne zasady anulowania wpłynęły na projekt API
E02	Booking	Coding	Testing	C-Logic	Medium	Yes	Brak limitu 3 rezerwacji wykryty dopiero testami

Error Case ID	Case Study	Stage Introduced	Stage Observed	Category	Severity	Propagated	Comment
E03	Booking	DevOps	DevOps	D-Config	Low	No	Błąd składni YAML

10. Zasady liczenia wyniku

Wynik artefaktu

Średnia z:

- Correctness
- Completeness
- Consistency
- Clarity
- Usefulness

Wynik etapu

Średnia z wszystkich artefaktów danego zespołu

Wynik pipeline

Średnia z:

- cross-phase consistency
- error propagation resistance
- final system quality

11. Referencyjny szablon krótkiego raportu oceny

A. Identyfikacja

- Case study:
- Team:
- Task:
- Mode:
- Model LLM:

- Liczba iteracji:

B. Dane wejściowe

- opis wejścia
- źródło danych (gold / pipeline)

C. Output

- krótki opis artefaktu

D. Ocena 0–3

- Correctness:
- Completeness:
- Consistency:
- Clarity:
- Usefulness:

E. Uwagi jakościowe

- główne mocne strony
- główne błędy
- czy błąd propaguje się dalej

F. Wniosek

- wynik akceptowalny / częściowo akceptowalny / nieakceptowalny

12. Referencyjny szablon raportu końcowego dla case study

1. Case study

Nazwa i krótki opis

2. Porównane tryby

- Human-only
- LLM-only
- Hybrid

3. Wyniki per etap

Tabela wyników dla:

- Requirements
- Architecture
- Coding
- Testing
- DevOps

4. Wyniki systemowe

- consistency end-to-end
- final quality
- error propagation

5. Najczęstsze błędy

Krótką listą z klasyfikacją

6. Wniosek

- gdzie LLM działa dobrze
- gdzie wymaga nadzoru
- gdzie hybrid daje przewagę

13. Do czego używać tego gold

Ten artifact może być użyty jako:

- gold evaluation protocol dla Evaluation Team,
- wspólny szablon raportowania dla wszystkich zespołów,
- punkt odniesienia do porównania wyników między case studies i trybami.

14. Uwaga

Gold dla Evaluation Team nie definiuje „jedynego słusznego wyniku”, tylko jednolity sposób oceny, raportowania i analizy, który zapewnia porównywalność wyników w całym projekcie.